


Ask your documents by voice

Повний звіт про прототип: що вимагав бриф і як це закрито, наскільки добре, якими інструментами і чому саме так — плюс усе, що зроблено понад завдання, і дрібниці, яких не видно з першого погляду.



Живий застосунок: плитка голосу, документи, відповідь «виведено з документа» з поясненням WHY, аркуші цитат і панель вимірювань. Кадр із запису екрана, не макет.

ДЕМО
askyourdocuments.vercel.app

РЕПОЗИТОРІЙ
github.com/AlekVoyan/test-CB

ДАТА
вересень 2026

Що просили — і що вийшло

Бриф: користувач завантажує мануал і питає вголос; сервіс коротко відповідає голосом і показує дослівну цитату зі сторінкою. Відповідь — лише з документа, заміна документа змінює відповідь. До двох текстових PDF, до десяти сторінок, одна мова, уточнювальні запитання і явне «в документі цього немає».

Вердикт

Вимоги брифу закриті, частина — з великим запасом

Основний сценарій — голос → відповідь → цитата зі сторінкою — працює end-to-end і на локальній машині, і на задепложеному демо. Усі шість типів запитань із брифу проходять 3/3. Жодну правдоподібну відповідь без підтвердження не було показано користувачеві ні в одному прогоні: це головна гарантія, яку бриф називає провалом, і вона тримається кодом, а не надією на модель.

Найсильніший доказ — **holdout 100%**: окремий документ про очищувач повітря, на якому промпт жодного разу не налаштовувався. Він прямо відповідає на пункт брифу «застосунок обробляє новий вхід, а не підготовлені відповіді».

Чесно

Що не ідеально

- **A6** — висновок із винятку — нестабільний: 1/3 і 3/3 у двох останніх прогонах без змін у коді. Відмова безпечна, але відповіді немає.
- Усі цифри зняті на безкоштовному ендпоінті NVIDIA з великим розкидом і лімітом 429; цільова Claude Haiku 4.5 чекає поповнення балансу.
- Витрачено більше за вісім орієнтовних годин — нижче розкладено, на що.

Час

4.5 год

на сам бриф: витяг тексту, пошук, контракт відповіді, валідатор, eval, голосовий сценарій, UI, заміри — у межах восьми годин

~16 год

понад бриф, з власного рішення: візуальна система, три голоси, розуміння запитання, мови, скани

20.8 год

усього за журналом — 50 записів із початком і кінцем кожного етапу

Орієнтир брифу — «до восьми зосереджених годин». Основний сценарій був завершений і перевірений у їхніх межах; усе інше — свідомо додана глибина, записана порядково в docs/TIME_LOG.md.

З чого складається задача

Робоче демо

Vercel Hobby: статичний SPA і дві serverless-функції — /api/answer та /api/tts. Ключі живуть лише на сервері.

Репозиторій

README з картою коду, .env.example, фікстури з вихідниками, eval зі звітами, delivery notes, журнал часу, дизайн-система.

Відео

Сценарій на 2:55, дев'ять сцен записані Playwright і змонтовані в Remotion; два дублі з живим мікрофоном знімаються вручну.

Кожен пункт листа — і чим він закритий

Вимога	Статус	Як закрито і чим доведено
Спитати голосом, коротко почути відповідь	закрито	Web Speech API, автовідправлення фінального транскрипту; відповідь 1–2 речення (≤45 слів) озвучується одним із трьох голосів. Голосом у Chrome: кінець мовлення → перший звук, медіана 2.07 с.
Видима цитата зі сторінкою	закрито	Модель повертає лише ID рядків; текст цитати підставляє код з індексу — дослівність за побудовою. Сторінка видна на вкладці аркуша, а «Open in page» відкриває сам PDF з рамками.
Відповідь лише з документа	закрито	Валідатор: кожне число відповіді має бути в процитованому рядку або в запитанні; неперевірена відповідь ніколи не озвучується. Критичних провалів 0 в усіх прогонах.
Заміна документа змінює відповідь	закрито	M6: v1 → v2, 20 → 24 одиниці, 3/3; відповідь змінилася в 6/6 прогонів. Історія діалогу при зміні документів скидається (A8).
До 2 PDF, до 10 сторінок, без OCR	закрито	Ліміти в config.ts; тести I1–I3 в npm test: третій файл, 11 сторінок, PDF без текстового шару — зрозуміле повідомлення, попередні документи лишаються.
Уточнення «а в іншій моделі?»	закрито	M3 і H3 3/3: запитання переписується в самостійне за історією останніх чотирьох реплік.
Явно сказати, що відповіді немає	закрито	M5, A4, H5 3/3, нуль цитат. Понад бриф — відмова підказує, про що документ говорить поруч.
Вигаданий мануал: 2 моделі, кроки, ліміти, виняток	закрито	Kestrel Dosing System, Model A і B, виняток на стор. 3, навмисні числа-відволікачі (12 V поруч із 12 units, 15 днів поруч із 15 units).
Шість запитань + очікування і сторінки	із запасом	M1–M6 плюс A1–A9, R1/R1b/R2, H1–H5, L1–L7, X1–X5: 37 тестів. expected.json закомічено до першого прогону — git є доказом.
Factual і citation окремо; «правдоподібно без підстав» = провал	закрито	Дві шкали на кожен прогон і окремий лічильник критичних провалів, який ніколи не вважається успіхом.
Індексація окремо від «запитання → перший звук»	закрито	153 мс проти 2.29 с на проді; розбивка розпізнавання / пошук / модель / перевірка / голос прямо в інтерфейсі.
Вартість: розпізнавання, модель, голос, повтори, посередники; хостинг окремо	закрито	Усі п'ять рядків пораховано; безкоштовний доступ оцінено за прайсом платного провайдера, як вимагає бриф; хостинг \$0 окремо.
Корекція, неоднозначність, відмова робити висновок	закрито	Корекція (R2) — 3/3. Відмова вгадувати: M5, A4, X5 — 3/3, 0 вигаданих відповідей. Неоднозначність: запитання «яка модель?» ставить код, а відповідь голосом «Model B.» склеюється з початковим запитанням — R1 і R1b 3/3 (раніше R1b від 0/3 до 3/3).
Інструменти ШІ і один приклад перевірки їхнього результату	закрито	Claude Code (Opus 5), ChatGPT і Gemini для чернетки T3; перевірка — ручна звірка цитати з відрендереною сторінкою PDF і npm run verify-example.
Заміри замість обіцянок; що зламалося; час	закрито	Усі вісім повних прогонів у звіті, не найкращий; незаміряне позначено TBD; журнал часу порядково.
Робоче демо, репозиторій, відео ≤3 хв	демо, код — так	Демо і репозиторій готові; відео змонтовано начорно, чекає живих дублів із мікрофоном.

37 тестів, по три прогони

Кожна сесія стартує з порожнього стану і йде за кроками: завантажити, спитати, видалити. Оцінювання йде по реальних PDF через той самий код, що й у застосунку — очікувані відповіді в пайплайн не підставляються.

● Звітний прогін · результат на тест

ID	Тип	Запитання	Пройшов
M1	прямий факт	What is the maximum for Model A?	3/3
M2	порівняння	How do I set up Model A versus Model B?	3/3
M3	уточнення	And what about the other model?	3/3
M4	виняток	Is Model B ever allowed to exceed its normal limit?	3/3
M5	факту немає	What is the battery life of Model A?	3/3
M6	після заміни v1 → v2	What is the maximum for Model A? → 24	3/3
R1 · R1b	неоднозначність → уточнення голосом	What is the limit? → Model B.	3/3 · 3/3
R2	корекція	I meant Model B.	3/3
A1-A5	конфлікт, перефраз, числа-відволікачі, невідома модель, перейменований файл	anti-hardcode: v2 завантажено під назвою manual-v1.pdf	15/15
A6-A9	висновок із винятку, помилка розпізнавання («model bee»), скидання історії, огляд документа	Can Model B run at 15 units when it's 25°C?	12/12
H1-H5	holdout — незнайомий документ	room size, filters, follow-up, night mode, price	15/15
L1-L7	російська й українська, зміна мови посеред сесії	А яке максимальне навантаження моделі B?	21/21
X1-X5	висновок із діапазону, непрямий факт, пов'язаний рядок, обмовки	How often should I clean the nozzle?	12/15
I1-I3	ліміти входу	3 файли, 11 сторінок, PDF без тексту	pass

Розкид — чесний заголовок

Шість повних прогонів за день на одному коді: PO від **86.7%** до **96.7%** — температура 0, промпт однаковий, різниця лише в семплінгу. Сьомий і восьмий, після виправлень у коді, — **100%**. У звіт ідуть **усі** прогони.

Holdout — 100% у кожному. Критичних — 0 у кожному.

Прогін	P0	P1	Holdout	Крит.
08:09	96.7%	96.3%	100%	0
08:20	90.0%	92.6%	100%	0
08:46	93.3%	100%	100%	0
11:17 · перевірка недочувань	91.7%	96.3%	100%	0
13:55 · попередній звітний	86.7%	91.7%	100%	0
14:20 · той самий код*	90.6%	100%	100%	0
12a9764 · уточнення в коді	100%	92.6%	100%	0
8d4f0fd · звітний	100%	100%	100%	0

* 41 зі 111 запитань повернулися з 429 — прогін неповний, не зараховано.

Як проходить одне запитання

Документи, індекс та історія живуть у браузері; сервер — stateless-проксі, який зберігає ключ і сам збирає промпт. Той самий ізоморфний код src/core працює в браузері, на сервері та в eval.

PDF → текст
pdf.js, рядки за координатами, колонки, склеювання переносів

Індекс
рядки-одиночки з ID d1:p2:s3 і рамками на сторінці

Пошук
BM25 з entity-токенами model_a; увесь корпус або top-k за словами і змістом

Модель
structured output за JSON-схемою, zod, temperature 0

Валідатор
правила статусів і чисел, один повтор із підказкою

Цитати
текст з індексу за ID, повторна перевірка в браузері

Голос
розпізнавання Web Speech API · озвучення одним із трьох голосів · момент першого звуку міряється за виходом аудіо, а не за надходженням відповіді

● стек продукту

Інтерфейс	React 18 · Vite · TypeScript strict · Phosphor Icons
PDF	pdfjs-dist 6 · декодери JBIG2 і JPEG 2000 на WebAssembly
Контракт	zod + JSON Schema для провайдерів без zod
Модель	Claude Haiku 4.5 (ціль) · NVIDIA Nemotron 3 Super (рантайм)
Голос	Web Speech API · ElevenLabs Flash v2.5 · Supertonic 3 на ONNX Runtime Web + WebGPU
Хостинг	Vercel Hobby, дві функції
Тести	Vitest (131) · власний eval-харнес

Як працював

Розробка	Claude Code на Claude Opus 5 — код, тести, документи під моїм керівництвом
Чернетка T3	ChatGPT і Gemini, потім переписана через Claude Code
Дизайн	скіли impeccable, emil-design-eng, animate; DESIGN.md як контракт
Перевірка UI	Playwright: кадри високої щільності, покадровий розбір анімацій
Заміри	CDP, performance.now(), прогони на проді
Відео	Playwright → ffmpeg → Remotion


Чому дві моделі
Ключ Anthropic виявився з нульовим балансом у першу ж годину. Пайплайн від самого початку стояв за інтерфейсом LlmClient, тому другий адаптер — NVIDIA Nemotron на безкоштовному ендпоінті — зайняв один етап, а не переписування. Його результати звітовані окремо й оцінені за прайсом платного провайдера тієї ж моделі: «безкоштовні кредити — не нульова вартість», як вимагає бриф. Перемикання назад — одна змінна оточення.

Що обрано — і чому це краще за альтернативи

Рішення	Чому	Чим краще за альтернативу
Модель повертає ID рядків, цитату пише код	Цитата дослівна за побудовою: модель фізично не може її перефразувати.	Проти «модель сама пише цитату»: там дослівність — обіцянка, яка перевіряється постфактум і часом порушується.
Увесь корпус у промпт (full), top-k як запасний	10 сторінок — кілька тисяч токенів; немає промахів пошуку на перефразах і уточненнях без ключових слів.	Проти RAG-фреймворку: для 10 сторінок це зайва інфраструктура і новий клас помилок пошуку. Коли документ не входить, сам вмикається top-k за словами і змістом.
Валідатор + один повтор, неперевірене не озвучується	Правило чисел ловить хибну цитату для правильного числа; повтор отримує список рядків, де число є.	Проти «довіряти моделі»: на безкоштовній моделі валідатор ловив хибно процитовані «12 units» — користувач їх жодного разу не побачив.
Документи в браузері, сервер без стану	Serverless не зберігає пам'ять; глядачі демо не бачать чужих документів; індексація коштує \$0.	Проти індексу на сервері: він губився б між викликами й потребував би сховища та ізоляції користувачів.
Скидання історії при зміні документів	Інакше «20 одиниць» із v1 протікає у відповідь після заміни на v2.	Ціна — уточнення не переживає заміну, і це тестується (A8).
Спершу аналіз, потім статус	Коли статус ішов першим, модель вирішувала «не знайдено» до читання і потім виправдовувалась. Приватний аналіз перед статусом це виправив.	Заміряно А/В упереміш: ~34 зайві токени і жодної вимірної затримки.
Сервер сам збирає промпт	Клієнт надсилає запитання, історію і рядки — не текст промпту.	Проксі не можна використати як безкоштовний доступ до моделі; плюс ліміти тіла запиту і rate limit.
Автовідправлення транскрипту	Швидше; транскрипт видно й можна редагувати, голосова корекція «I meant Model B» працює.	Проти кнопки підтвердження: зайвий клік у голосовому продукті. Ціна — недочуте слово йде одразу, тому з'явилася перевірка недочувань.
Без OCR	Бриф виключає скани; документ, що входить, іде цілком і не потребує векторів.	Скан без текстового шару відхиляється зрозумілим повідомленням; скан з OCR-шаром приймається і відповідає.
Очікування закомічені до прогону, holdout не чіпається	Git доводить, що правильні відповіді записані до тестування.	Проти підгонки: двічі виправлення промпту погіршувало інші тести — це побачили лише тому, що тест був написаний заздалегідь.

Цитата, якій можна вірити

Цитата — це не фраза поруч із відповіддю, а вказівник у джерело. Її можна відкрити в самій сторінці PDF і побачити, звідки взято кожен рядок.



Open in page


Панель рендерить **сам PDF** через pdf.js, а не наш витягнутий текст. Процитований абзац підсвічено, решта сторінки йде під вуаль 42%, кожен процитований рядок обведено рамкою.

Зум 100–300% кнопками, клавішами + - 0, щипком або Ctrl/⌘ зі скролом — навколо точки під курсором; зображення масштабується одразу й перемальовується чітко, коли жест завершився, в offscreen-canvas, щоб не блимати.

Скани і дві колонки

Сканований журнал 1927 року з Internet Archive: сторінка — зображення JBIG2 під невидимим OCR-шаром. Рамки стають усередину тієї колонки, з якої прийшли рядки.

Колонка визначається за порожньою вертикальною смугою на всю висоту регіону; таблиця «мітка — значення» не ріжеться, а в колонки може бути своя вкладена пара колонок.



Подвійна перевірка

Підрядок сторінки перевіряє сервер, а потім ще раз браузер — за своїм локальним індексом. Не збіглося — відповідь приховується.

Правило чисел

Число у відповіді має бути в процитованому рядку або в запитанні. Інакше — повтор зі списком рядків, де це число є.

Аркуш абзацу

Процитовані рядки — у фокусі за чорнильною лінійкою, сусідні розчиняються маскою: аркуш читається як вирізка зі сторінки.

Три голоси одним перемикачем

Продукт голосовий, а системні голоси звучать як робот і відрізняються на кожному комп'ютері: у перевіряльника на Windows може не бути російського чи українського голосу взагалі. Тому голос — вибір, а не випадковість.

Built-in

Системний

speechSynthesis браузера. Безкоштовно, стартує миттєво — і лишається запасним для двох інших: якщо обраний голос не може говорити, звучить цей, а причина пишеться в метрики.

● ElevenLabs


Нейронний

Flash v2.5, обраний прослуховуванням проти v3 і голосів macOS: перший байт 208 мс проти 749 мс і вдвічі дешевше. PCM потоком у Web Audio, звук стартує з першого чанка. $\approx \$0.0046$ за відповідь.

On device

Локальний, безкоштовний

Supertonic 3 (99M) у Web Worker на ONNX Runtime Web: WebGPU, WebAssembly як запасний. Модель завантажується один раз (399 МБ) і живе в Cache Storage.



Захист платного голосу

/api/tts вимовляє лише текст, який /api/answer підписав HMAC-квитком, із ключем, виведеним з API-ключа. Публічне демо не можна використати як безкоштовний TTS-проксі.

Локальний голос за 0.75 с

Перша версія починала говорити через 2.7–5.4 с: довгі речення синтезувалися цілком, а кожна нова довжина входу змушувала WebGPU збирати ядра заново. Тепер перший шматок короткий (до 64 символів, ріжеться по кінцю речення, комі або між словами), у кожного виду шматка одна фіксована форма тензорів, прогріта під час завантаження, а нова відповідь скасовує стару між кроками денойзингу. Підсумок — **0.74–0.79 с** до першого звуку; WebGPU $\approx 9\times$ швидше за WebAssembly.

Неочевидне

- **Autoplay.** Браузер дозволяє звук лише після жесту, а відповідь приходить через секунди після тапу — тому AudioContext «праймиться» прямо на натисканні мікрофона.
- **Перший звук міряється чесно:** момент, коли звук дійде до виходу (з урахуванням outputLatency), а не коли прийшла відповідь.
- **Мову голосу закріплено** (language_code), щоб український текст не читався з російською вимовою.

Коли запитання неточне, а відповідь не написана прямо

Реальні мануали відповідають на запитання, яких дослівно не містять, а розпізнавання мовлення чує не ті слова. Усе нижче зроблено без режиму міркувань і майже все — без жодного зайвого виклику моделі.

Q Is Model B ever allowed to exceed its normal limit?

Inferred from the document "Is Model B ever allowed to exceed its normal limit?"

Yes, Model B may exceed its normal limit of 12 units under specific conditions.

WHY The exception for Model B allows operation up to 15 units for no more than 5 minutes when ambient temperature is below 20°C.

Speaking Using manual-v1.pdf · Model B

Висновок із правила з поясненням — показується і промовляється.

Q What is the battery life of Model A?

Not in the document "What is the battery life of Model A?"

The uploaded documents do not specify the battery life of Model A.

Closest in this document

Setup: Model A Model A: the maximum load is 20 units. There is no exception for Model A

Speaking Using manual-v1.pdf

Відмова, яка підказує, про що документ говорить поруч.

Висновок із поясненням

«Чи може Model B працювати за 40°C?» — у тексті немає, але є діапазон 5–35°C. Відповідь позначається *виведено* і має рядок **WHY** із правилом. Хибний висновок вважається **критичним** провалом — це новий спосіб помилятися, і він оцінюється суворіше.

Перевірка недочувань

Слово, якого немає в документі, згортається фонетично (дзвінки/глухі пари, ненаголошені голосні, ph → f) і шукається серед слів документа. Один кандидат — підставляється й називається у відповіді. Два і більше — запитання повертається **без виклику моделі**: \$0 і 0 мс.

Слово документа

Коли відповіді немає, модель може назвати, яким словом документ називає те, про що спитали. Це слово показується першою підказкою — але лише якщо воно справді є в рядках документа, інакше мовчки відкидається.

Мова відповіді

Українське запитання після російського часом отримувало російську відповідь. Тепер абетка й частотні слова перевіряються, промах коштує одного повтору — а якщо й повтор мимо, відповідь зберігається: правильна відповідь чужою мовою краща за «не зміг перевірити».

Запитання із заголовків

Будь-який завантажений документ відкривається трьома запитаннями за його власними заголовками — замість прикладів про чужий мануал.

Другий прохід пошуку

Якщо документ не входить у промпт, найкращі знайдені рядки віддають рідкісні слова назад у запит — і другий пошук знаходить те, що перший пропустив.

Обмовку названо

Якщо модель мовчки виправила «nozzel» на «nozzle», код це помічає й називає: «Assuming you meant “nozzle”».

«Тека з доказами»

Картотека, відкрита вночі: кожна відповідь — тека, а рядок, який її доводить, підшитий за нею під вкладкою, на якій написано сторінку. Силует вкладки — не прикраса: вкладка з'являється, лише коли несе дані.

Відповідь
#d5ea74

Голос
#ef9175

Документи
#74c7ba

Доказ
#a8d996

Плівковий чорний
#161714

● Правило однієї ролі

Кожен пастельний колір означає одне — у плитках, кружках і сегментах графіка затримок: лайм — відповідь, корал — голос, бірюза — документи, шавлія — доказ. Колір ніколи не використовується як декор. Чорний піднято до плівкового #161714 із зерном: чистого чорного немає ніде.

Типографіка

Unbounded — широкий голос лише для назв і заголовків. **Onest** — для відповіді й усього, що читається. JetBrains Mono — лише там, де щось виміряно: таймінги, токени, вартість, ID рядків. Усі три гарнітури покривають кирилицю разом з і ї є ґ.

Геометрія вкладки

Плитка — прямокутник із радіусом 28 px. У теки лівий верхній кут прямий, над ним вкладка: опуклий кут 14 px переходить у ввігнуте заокруглення 14 px. **Висота вкладки дорівнює двом радіусам** — тому край читається однією безперервною S-кривою.

Вкладка не має власної висоти: вона тягнеться від лінії ряду до кромки своєї теки, а кут і заокруглення — рівно половина цієї відстані. Тому в дальньої, коротшої вкладки крива теж не ламається. Глибина і підйом під час наведення — дві зареєстровані довжини @property: висота, кути й кромка рахуються з одного інтерпольованого значення на кожному кадрі — розрив між ними 0.01 px замість 1.3 px.

$p.2 \cdot \text{вкладка}$  $28 = 2 \times 14$

опуклий кут → ввігнуте заокруглення
одна безперервна S-крива

Колір належить плану

Передній план — повний лайм, кожен глибший план — на чверть до оливкового (0.086 за світлістю oklab). Вийшла вперед — посвітлішала; пішла назад — потемнішала.

Вкладки не стрибають

Кожна вкладка має своє місце в ряду. Вихід теки вперед змінює лише глибину, а колір розтікається з-під її вкладки диском за 280 мс.

Тінь за силуетом

Вкладка відкидає тінь разом із плиткою, без шва. Тіні — box-shadow шарами, не drop-shadow фільтр (про це — в дрібницях).

Анімація як сенс, а не ефект

Кожен рух відповідає на запитання «навіщо»: підшити відповідь у теку, показати, звідки прийшов колір, підтвердити натискання. Усе, що повторюється десятки разів, — швидко; те, що видно один раз, може дозволити собі характер.

Рух	Параметри	Навіщо саме так
Поява плиток	600 мс · крок 100 мс · підйом 200 px / 64 px на телефоні · квадратичний ease-in-out	Один раз за завантаження, тому єдиний виняток із правила «до 300 мс». Обидві половини — параболи: рівний розгін і рівне гальмування до м'якої зупинки.
Відповідь підшивається	320 мс · підйом 10 px · блюр 3 px → 0	Блюр склеює два стани, і око бачить одне перетворення, а не підміну; аркуші цитат ідуть слідом із кроком 50 мс.
Вихід теки вперед	диск з-під вкладки · 280 мс · cubic-bezier(0.23, 1, 0.32, 1)	Показує, звідки прийшов колір. Анімується масштаб диска, а не clip-path — композитор Chrome зміщував центр кола під час руху.
Наведення на теку	підйом теки · 160 мс	Тека піднімається цілком — вкладка і кромка разом, щоб силует не ламався. Лише для точних вказівників: на тачскрині хибних hover немає.
Натискання	scale 0.97 · 140 мс	Миттєвий відгук: інтерфейс «почув» натискання.
Перемикачі	індикатор їде 220 мс · ease-out	Мова, голос, «думати довше»: обране стає коралом.
Мікрофон і мовлення	кільце кожні 1.6 с · еквайзер із трьох смуг	Стан «слухаю» і «говорю» читається без слів.
Перегляд сторінки	панель зліва на десктопі · аркуш знизу на телефоні	На десктопі відповідь і аркуші лишаються видимими праворуч; Esc, хрестик або фон закривають, фокус повертається на кнопку.

● Reduced motion


Кожна анімація має щадний варіант: плитки лише проявляються з кроком 40 мс, теки змінюють глибину на місці, колір змінюється одразу, еквайзер і кільце мікрофона зупиняються. Не «нуль руху», а «менше і м'якше».

Сітка

Бенто на 12 колонок до 1280 px: голос ліворуч на два рядки, документи й відповідь праворуч, відповідь — найбільша плитка. Нижче 1100 px — 6 колонок, нижче 720 px — одна колонка в порядку читання: голос → документи → відповідь → докази → вимірювання.

Поверхні браузерів

Виділення тексту — лайм із чорнилом, каретка — лайм, темні скролбари, видимий фокус: 2 px із відступом, чорнило на пастелі й лайм на темному.



Телефон, 390 px: та сама логіка в одну колонку.

Неочевидні рішення, яких не видно одразу

01 • ТІНІ І ГОЛОС

Тінь забирала GPU в голосу

Тіні плиток були drop-shadow фільтром. Фільтр перераховується щокадру, поки всередині чи поверх щось рухається — відповідь підшивається, еквалайзер грає. Це забирало половину GPU в локального голосу: синтез ішов 1.5–2.1 с замість 0.7 с. Заміряв серією експериментів, перевів на box-shadow шарами.

02 • ТЕКСТ

Крапка після «1938г.» розривала факт

Рядок, що закінчувався скороченням, вважався кінцем речення — факт відривався від своєї дати, і валідатор відкидав правильну відповідь за «числа немає в цитаті». Скорочення більше не закінчує рядок. Запитання «Что такое газогенератор?» після цього почало отримувати відповідь.

03 • ІДЕНТИФІКАТОРИ

ID рядка будь-якою абеткою

Відповідаючи російською, модель часом писала ID рядка кирилицею — d2:p2:c16 замість d2:p2:s16 — рядок «не знаходився», і правильна відповідь губилася. Тепер кириличні двійники, діапазони і пропущений префікс документа розпізнаються. Але документ не вгадується, якщо рядок із таким номером могли дати два файли.

04 • СКАНИ

Чому скан був білим

pdf.js декодує JBIG2 і JPEG 2000 модулями WebAssembly, які підвантажують за URL, а не тримає в бандлі. Без них зображення сторінки мовчки не малювалося, а цитати при цьому були точними — з OCR-шару. Декодери, CJK-таблиці та шрифти тепер роздаються під /pdfjs.

05 • НЕДОЧУВАННЯ

«Model C» ніколи не стане «Model B»

Перевірка недочувань не чіпає однолітерні ідентифікатори і слова після «model/модель»: підставити сусідню модель — це саме правдоподібна відповідь без підстав. Плюс ≥6 літер, список повсякденних слів і однаковий перший звук: інакше «являється» підставлялося замість «появляється».

06 • ЗАМІРИ

Кінець мовлення — не завжди speechend

Chrome часом надсилає speechend уже після фінального результату, і розпізнавання «займало» 0 мс. Кінцем мовлення тепер вважається speechend або останній проміжний результат — що раніше.

07 • МОВА

Повтор не викидає добру відповідь

Перша версія перевірки мови витрачала єдиний повтор на мову; якщо друга відповідь ламала інше правило — губилася і валідна перша. Eval це впіймав. Тепер відповідь, відкинута через мову, запам'ятовується і повертається, якщо кращої не знайшлося.

08 • ЧИСЛА

Відкинута «розумна» ідея

Пробував автоматично дописувати цитату на сусідній рядок, де лежить число. Тести показали: так можна причепити рядок, який твердження не підтверджує. Відкотив — суворе правило лишилося, а лагодити треба було розбір тексту (дрібниця №2).

Ще дванадцять деталей

09

Колесо лише над вкладами

Колесо гортає ряд тек лише над смугою вкладок і відпускає сторінку на краях — не перехоплює прокручування сторінки.

10

Ранні відповіді — лише перегляд

Клік по старій вкладці відкриває стару відповідь, але уточнення завжди йде від останньої; кнопка «Back to latest» повертає.

11

«Model bee»

Розпізнавання пише літеру моделі словом. Код повертає літеру після «model», і запитання більше не перетворюється на уточнення.

12

Підказки без сміття

Під відмовою не пропонуються уривки рядків, підписи до рисунків і переліки кодів моделей.

13

Пов'язане — не доказ

Близькі до відмови рядки лежать у темних теках із бірюзовим текстом, ніколи в шавлії: шавлія — лише для доказу.

14

Скидання, яке видно

При зміні документів з'являється «Documents changed — conversation context reset»: користувач знає, чому уточнення не спрацювало.

15

Безкоштовне ≠ нуль

Nemotron на безкоштовному ендпоінті оцінено за прайсом OpenRouter за ту саму модель: \$0.085 / \$0.40 за мільйон токенів.

16

Холодний старт чесно

Функцію Vercel заміряно після 45 хвилин простою: 1.12 с проти ~0.4 с теплої — перше запитання після паузи на 0.7 с повільніше.

17

Цитати за абзацами

Широке запитання по односторінковому резюме цитувало 26 рядків одним блоком. Тепер кожен абзац — окремий аркуш із заголовком за першим рядком.

18

Колонки в резюме

Таблиця «мітка — значення» не ріжеться на колонки: з обох боків розрізу має бути зв'язний текст.

19

Звіт із причинами

Звіт eval зберігає кожну відкинуту спробу та причину — видно не лише підсумок, а й чому знадобився повтор.

20

Важке — на вимогу

Декодери pdf.js (3.9 МБ) вантажаться, лише коли їх просить документ, а ONNX Runtime (25.7 МБ) — лише коли він потрібен локальному голосу або пошуку за змістом.

● Принцип за всіма дрібницями

Майже кожна деталь тут з'явилася одним шляхом: реальний документ або реальний замір показав проблему → причину знайдено, а не вгадано → виправлення перевірено тестом або прогоном → якщо виправлення щось ламало, його відкочували й записували як відкинуте. Тому в delivery notes є розділ «що не спрацювало» — і він корисніший за розділ «що спрацювало».

Заміряно, а не обіцяно

Усі цифри зняті на реальному застосунку. Майже весь час запитання — виклик моделі на безкоштовному ендпоінті; пошук і перевірка займають близько мілісекунди.

Індексція

153_{мс}

3 сторінки на проді, витяг 150 мс

Запитання → звук

2.29_с

медіана на проді, максимум 4.98 с

ElevenLabs

425_{мс}

до першого байта аудіо на сторінці

Розпізнавання

69_{мс}

медіана від кінця мовлення до транскрипту

Замір	Де	Результат
Запитання → перший звук, M1 / M4 / M5 × 5	Vercel + NVIDIA + ElevenLabs	2.42 / 2.65 / 2.11 с
Кінець мовлення → перший звук, 8 голосових запитань	Chrome 152	медіана 2.07 с
Локальний голос: відповідь → перший шматок синтезовано	WebGPU на Metal	0.74-0.79 с
Перше завантаження локальної моделі / з кешу	headless Chromium	≈35 с / 4-6 с
Запитання → перший звук, відповідь «не знайдено», один виклик	вбудований Chromium	1.23 с
Холодний старт функції після 45 хв простою	Vercel	1.12 с

● Вартість одного запитання

Індексція	\$0
Модель, Nemotron 3 Super (за платним прайсом)	\$0.00024
Модель, Claude Haiku 4.5 (оцінка)	≈\$0.0029
Голос ElevenLabs Flash v2.5, ~92 символи	≈\$0.0046
Голос на пристрої / системний	\$0
Повтори виклику (1.8% запитань) — уже всередині	враховано
Посередники	\$0
Разом із нейронним голосом	≈\$0.0048

Хостинг — окремо

Vercel Hobby, \$0 на місяць у межах лімітів тарифу.

Голос — головна стаття

Нейронний голос дорожчий за міркування в 18 разів на Nemotron і в 1.5 раза на Haiku. Тому є безкоштовний локальний варіант.

Джерела цін

Кожна ціна в docs/pricing.md — з URL і датою перевірки.

Що не закрито — і що я зробив би наступним

Відомі обмеження

- **А6 нестабільний.** На «Can Model B run at 15 units at 25°C?» модель часом міркує правильно, але оформлює це як «не знайдено»: 1/3 і 3/3 у двох останніх прогонах без змін у коді. Відмова безпечна.
- **Розкид ендпоінта.** Один прогін на безкоштовній моделі — слабкий замір; до шостого прогону за день ендпоінт різав 429.
- **Найку не заміряно** — баланс Anthropic був порожній; адаптер написано й покрито тестами.
- Уточнення «яка модель?» кодом розпізнає лише моделі виду «Model X»: для «Nimbus Pro» і далі вирішує модель.
- Підказки під відмовою не озвучуються: платний голос говорить лише підписаний сервером текст.
- На сканах журналів «заголовками» буває службова інформація титулу.


Що далі

- **Прогін на Claude Haiku 4.5** і перезамір A6 та X3 — насамперед.
- **Стримінг відповіді:** озвучувати перше речення, щойно воно пройшло перевірку.
- **Альтернативи розпізнавача:** обирати з кількох гіпотез Chrome ту, чий слова є в документі.
- **Серверне розпізнавання** для всіх браузерів із тимчасовими ключами.
- **Крок обчислення правил** для запитань «чи можна» і діапазонів замість тексту промπτу.
- **Документи між перезавантаженнями** (IndexedDB) і справжній rate limit на KV.

Як перевірявся результат ШІ

Автоматично, на кожній відповіді: неіснуючі ID, порушення правил статусу, число, якого немає в процитованому рядку, — і повторна перевірка підрядка в браузері.

Вручну, один приклад повністю: відповідь про виняток Model B відкрито через «Open in page»; рядок у рамці на відрендереній сторінці звірено з цитатою слово в слово і число в число; те саме запитання перефразовано — той самий рядок і сторінка; відволікачі «15 days» і «no exception for Model A» у відповідь не потрапили. Повторюється командою `npm run verify-example`.



Головне, що я хотів показати цим прототипом: не «модель розумна», а **система, яка не дає їй збрехати** — і чесний звіт про те, де вона все ще помиляється.